

Laporan Praktikum Kontrol Cerdas

Nama : Tegar Lalang Jagad

NIM : 224308021

Kelas : TKA-6A

Akun Github (Tautan) : <https://github.com/tegarlj19>

Student Lab Assistant : Yulia Brillianty

1. Judul Percobaan

Reinforcement Learning For Autonomous Control

2. Tujuan Percobaan

Tujuan dari percobaan praktikum Reinforcement Learning yaitu:

1. Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.
2. Mengimplemtasikan agen RL menggunakan algoritma *Deep Q-Network* (DQN).
3. Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom

3. Landasan Teori

Reinforcement Learning adalah proses mapping (pemetaan) dari situasi yang ada di environment (states) ke bentuk aksi (behavior) agar dapat memaksimalkan reward. Agent yang bertindak sebagai sang learner tidak perlu diberitahukan behavior apakah yang akan sepatutnya dilakukan, atau dengan kata lain, sang learner belajar sendiri dari pengalamannya. Salah satu konsep utama dalam Reinforcement Learning yaitu Agent. Dalam Reinforcement Learning (RL), Agent adalah entitas atau program yang mengambil keputusan dan berinteraksi dengan lingkungan untuk mencapai tujuan tertentu. Agent mengambil tindakan, mendapatkan feedback, dan belajar dari pengalaman untuk meningkatkan performanya. Tugas utama dari Agent yaitu mengamati lingkungan, memilih tindakan atau action, menerima feedback, dan memperbarui strategi. Maka dari itu Agent adalah inti dari Reinforcement Learning yang bertindak berdasarkan pengamatan lingkungan, menerima reward, dan terus belajar untuk meningkatkan kemampuannya.

Deep Q-Network (DQN) adalah algoritma dalam reinforcement learning yang menggabungkan Q-learning dengan jaringan saraf dalam untuk menyelesaikan masalah kompleks, sehingga memungkinkan agen untuk belajar dari pengalaman dan membuat keputusan dalam lingkungan yang rumit. Algoritma ini sangat berguna untuk menangani masalah dengan ruang keadaan yang besar, seperti pengenalan gambar dan kontrol robot, dengan memanfaatkan kemampuan jaringan saraf untuk mengekstrak fitur dari data secara efisien dan efektif. DQN bekerja dengan cara memanfaatkan jaringan saraf untuk memperkirakan nilai Q, yang merupakan nilai dari setiap aksi yang mungkin diambil dalam

suatu keadaan tertentu. Dengan menggunakan pemutaran ulang pengalaman, DQN menyimpan pengalaman masa lalu dalam memori dan mengambil sampel acak dari pengalaman tersebut untuk memperbarui model, sehingga meningkatkan stabilitas dan efisiensi pembelajaran. Selain itu, DQN juga menerapkan strategi eksplorasi epsilon-greedy, yang memungkinkan agen untuk menyeimbangkan antara eksplorasi tindakan baru dan eksploitasi tindakan yang sudah diketahui, sehingga agen dapat menemukan strategi yang optimal seiring waktu.

4. Analisis dan Diskusi

MountainCar-v0 adalah lingkungan di mana sebuah mobil harus mencapai puncak bukit meskipun tidak memiliki daya yang cukup untuk langsung mencapainya. Lingkungan ini memiliki ruang keadaan dua dimensi, yang terdiri dari posisi mobil di sepanjang bukit dan kecepatan mobil. Terdapat tiga aksi yang dapat diambil oleh agen, yaitu bergerak ke kiri, tetap diam, atau bergerak ke kanan. Agen harus memilih tindakan yang tepat untuk mengoptimalkan pergerakan mobil. Dalam lingkungan ini, agen menerima reward standar sebesar -1 untuk setiap langkah yang diambil, yang mendorong agen untuk mencapai puncak bukit secepat mungkin. Namun, dalam beberapa implementasi, reward ini dapat dimodifikasi untuk mempercepat proses pembelajaran. Tantangan utama adalah bahwa mobil harus mengayun bolak-balik untuk mendapatkan momentum yang cukup agar dapat mencapai puncak bukit. Reinforcement Learning (RL) digunakan untuk melatih agen dalam lingkungan ini. Agen belajar melalui interaksi dengan lingkungan, mencoba berbagai tindakan, dan menerima umpan balik dalam bentuk reward atau punishment. Dengan menggunakan algoritma RL, agen dapat mengembangkan kebijakan yang optimal untuk mencapai tujuan, belajar dari pengalaman sebelumnya, dan beradaptasi dengan kondisi yang berubah. Karena sifatnya yang kontinu. Penggunaan Deep Q-Network (DQN) menjadi pendekatan yang baik, karena DQN dapat menangani ruang keadaan yang besar dan kompleks dengan menggunakan jaringan saraf untuk memperkirakan nilai Q, sehingga memungkinkan agen untuk belajar dengan lebih efisien dalam mencapai puncak bukit.



5. Assignment

Pada praktikum ini yaitu implementasi dari algoritma Deep Q-Network (DQN) yang digunakan untuk melatih environment agen dalam environment MountainCar-v0. Tujuan dari agen ini yaitu mencapai puncak bukit dengan menggunakan aksi yang optimal. Kode dimulai dengan mengimpor beberapa library yang diperlukan, seperti gymnasium untuk environment reinforcement learning, numpy untuk operasi numerik, random untuk pemilihan acak, dan deque dari collections untuk menyimpan pengalaman. Selain itu, tensorflow.keras digunakan untuk membangun model jaringan saraf. Selanjutnya, terdapat kelas yang disebut DQNAgent, yang mendefinisikan agen DQN. Agen diinisialisasi dengan ukuran keadaan dan ukuran aksi. Beberapa parameter penting juga digunakan, seperti gamma yang berfungsi sebagai faktor diskon, epsilon yang merupakan parameter untuk eksplorasi, dan learning_rate yang digunakan untuk optimasi model.

Pada eksperimen pertama CartPole-V1, agen harus menjaga tiang tetap tegak di atas gerobak/kotak. Lingkungan ini cukup sederhana, sehingga agen dapat belajar dengan cepat. Setiap kali agen berhasil menjaga tiang tetap tegak, ia mendapatkan reward positif. Pelatihan untuk CartPole bisa dilakukan dalam waktu singkat, hanya dalam beberapa ratus episode. Agen dapat dengan stabil mencapai tujuannya karena lingkungan ini lebih mudah diprediksi. Sedangkan, pada MountainCar-v0, agen harus menggerakkan mobil ke puncak bukit, tetapi mobil tidak memiliki cukup tenaga untuk langsung mencapai tujuan. Agen harus belajar membangun momentum dengan bergerak maju dan mundur. Reward di MountainCar-v0 lebih susah karena mobil tidak berhasil mencapai puncak, yang membuat pembelajaran menjadi lebih sulit. Model yang digunakan

memerlukan arsitektur yang lebih kompleks atau teknik tambahan untuk meningkatkan stabilitas. Proses pelatihan untuk MountainCar memerlukan lebih banyak episode. sebelum agen dapat mencapai kinerja yang baik. Pembaruan nilai dalam lingkungan ini bisa lebih berfluktuasi, sehingga kembali ke skor yang lebih tinggi.

6. Data dan Output Hasil Pengamatan

No	Variabel	Hasil Pengamatan	
		Cartpole	Mountain car
1	Hasil Score Awal(DQN)	Episode: 9/20, Score: 11, Epsilon: 0.93 Episode: 10/20, Score: 21, Epsilon: 0.92 Episode: 11/20, Score: 29, Epsilon: 0.91 Target Network updated! Episode: 12/20, Score: 19, Epsilon: 0.90 Episode: 13/20, Score: 20, Epsilon: 0.90 Episode: 14/20, Score: 11, Epsilon: 0.89 Episode: 15/20, Score: 25, Epsilon: 0.88 Episode: 16/20, Score: 8, Epsilon: 0.87 Episode: 17/20, Score: 23, Epsilon: 0.86 Episode: 18/20, Score: 8, Epsilon: 0.85 Episode: 19/20, Score: 32, Epsilon: 0.84 Episode: 20/20, Score: 18, Epsilon: 0.83	Target Network updated! Episode: 2/20, Score: 199, Epsilon: 0.99 Episode: 3/20, Score: 199, Epsilon: 0.99 Episode: 4/20, Score: 199, Epsilon: 0.99 Episode: 5/20, Score: 199, Epsilon: 0.98 Episode: 6/20, Score: 199, Epsilon: 0.98 Episode: 7/20, Score: 199, Epsilon: 0.97 Episode: 8/20, Score: 199, Epsilon: 0.97 Episode: 9/20, Score: 199, Epsilon: 0.96 Episode: 10/20, Score: 199, Epsilon: 0.96 Episode: 11/20, Score: 199, Epsilon: 0.95
2	Hasil Score Akhir (DQN)	Episode: 950/1000, Score: 166, Epsilon: 0.01 Episode: 951/1000, Score: 211, Epsilon: 0.01 Target Network updated! Episode: 952/1000, Score: 234, Epsilon: 0.01 Episode: 953/1000, Score: 229, Epsilon: 0.01 Episode: 954/1000, Score: 182, Epsilon: 0.01 Episode: 955/1000, Score: 171, Epsilon: 0.01 Episode: 956/1000, Score: 153, Epsilon: 0.01 Episode: 957/1000, Score: 139, Epsilon: 0.01 Episode: 958/1000, Score: 151, Epsilon: 0.01 Episode: 959/1000, Score: 175, Epsilon: 0.01	Episode: 983/1000, Score: 199, Epsilon: 0.01 Episode: 984/1000, Score: 199, Epsilon: 0.01 Episode: 985/1000, Score: 199, Epsilon: 0.01 Episode: 986/1000, Score: 199, Epsilon: 0.01 Episode: 987/1000, Score: 199, Epsilon: 0.01 Episode: 988/1000, Score: 199, Epsilon: 0.01 Episode: 989/1000, Score: 199, Epsilon: 0.01 Episode: 990/1000, Score: 199, Epsilon: 0.01 Episode: 991/1000, Score: 199, Epsilon: 0.01
2	Hasil Score (Test)	Test Episode: 1, Score: 23 Test Episode: 2, Score: 15 Test Episode: 3, Score: 18 Test Episode: 4, Score: 22 Test Episode: 5, Score: 53 Test Episode: 6, Score: 31 Test Episode: 7, Score: 16 Test Episode: 8, Score: 23 Test Episode: 9, Score: 20 Test Episode: 10, Score: 23	Test Episode: 1, Score: 199 Test Episode: 2, Score: 199 Test Episode: 3, Score: 199 Test Episode: 4, Score: 199 Test Episode: 5, Score: 199 Test Episode: 6, Score: 199 Test Episode: 7, Score: 199 Test Episode: 8, Score: 199 Test Episode: 9, Score: 199 Test Episode: 10, Score: 199
3	Hasil Run		

7. Kesimpulan

Berdasarkan praktikum dan analisis yang telah dilakukan, maka dapat diambil kesimpulan yaitu:

1. Penggunaan target network membantu stabilitas pembelajaran, menghindari perubahan nilai Q yang terlalu drastis.
2. MountainCar-v0 lebih sulit dipelajari karena *reward* hanya diberikan saat mencapai puncak bukit, memerlukan strategi eksplorasi lebih lama, dan mengandalkan momentum untuk berhasil. Sedangkan Cartpole lebih cepat karena agen dapat menerima reward setiap Langkah yang menjadikannya lebih optimal

8. Saran

Untuk meningkatkan agar performa agen DQN lebih baik bisa menerapkan *Target Network* untuk meningkatkan stabilitas dan mencegah model dari *overfitting* terhadap pola jangka pendek, dengan cara memperbarui target *network* secara periodik. strategi epsilon *decay* yang lebih adaptif, seperti menyesuaikannya berdasarkan performa, dapat memperbaiki keseimbangan eksplorasi dan eksploitasi. dapat mengoptimalkan *hyperparameter* seperti gamma, learning rate, dan epsilon

9. Daftar Pustaka

Angelina, L., Purwanto, Y., & Novianty, A. (n.d.). *Pengambilan Keputusan Pada Trafik Management Dengan Menggunakan Reinforcement Learning Decision Making on Traffic Management Using Reinforcement Learning*

Baradja, A., & Tjendrowasono, T. I. (2024). *Pengaplikasian Deep Reinforcement Q-Learning Untuk Prediksi Perdagangan Valas Otomatis*. *Jurnal Rekayasa Sistem Informasi dan Teknologi*, 1(3), 190–198. <https://doi.org/10.59407/jrsit.v1i3.519>